

 AutoSecure Insurance

Navigare

- ☐ 1. Date brute
- ☒ 2. Curățare date
- ☐ 3. Statistici descriptive
- ☐ 4. Clusterizare KMeans
- ☐ 5. Regresie logistică
- ☐ 6. Regresie OLS
- ☐ 7. Concluzii

Curățare date

a) Definirea problemei

Datele brute conțin valori lipsă, outlieri și variabile categorice care nu pot fi folosite direct în algoritmi de machine learning. Scopul este obținerea unui set de date curat, complet și pregătit pentru analiză predictivă.

b) Informații necesare

- Coloane cu valori lipsă — CREDIT_SCORE, ANNUAL_MILEAGE
- Valori lipsă numerice — completate cu media coloanei
- Outlieri — detectați prin metoda IQR (Interquartile Range)
- Codificare — LabelEncoder pentru variabile categorice (AGE, GENDER, etc.)
- Scalare — StandardScaler pentru variabile numerice

c) Metode de calcul și formule

Metoda IQR pentru detectarea outlierilor

$$IQR = Q_3 - Q_1$$

$$\text{Lower} = Q_1 - 1.5 \times IQR \quad \text{Upper} = Q_3 + 1.5 \times IQR$$

Orice valoare sub Lower sau peste Upper e considerată outlier și eliminată.

StandardScaler pentru normalizare

$$z = \frac{x - \mu}{\sigma}$$

d) Prezentarea rezultatelor


Completare valori lipsă numerice cu media

	Coloană	Lipsă înainte	Lipsă după	
0	CREDIT_SCORE	982	0	0
1	ANNUAL_MILEAGE	957	0	1
2	MARRIED	0	0	0
3	CHILDREN	0	0	0

Detecție și eliminare outlieri (IQR)

	Coloană	Q1	Q3	IQR	Lower bound	Upper bound
0	CREDIT_SCORE	0.43	0.61	0.18	0.17	
1	ANNUAL_MILEAGE	10000	13000	3000	5500	
2	SPEEDING_VIOLATIONS	0	2	2	-3	
3	PAST_ACCIDENTS	0	2	2	-3	

Număr de outliers detectați per coloană (metoda IQR)



Înainte

10,000

După curățare

7,871

Eliminate

2,129

Codificare (LabelEncoder)

	Coloană	Valori unice	Exemplu original	Exemplu codificat
0	AGE	4	65+	3
1	GENDER	2	female	1
2	DRIVING_EXPERIENCE	4	0-9y	0
3	INCOME	4	upper class	3
4	VEHICLE_YEAR	2	after 2015	1
5	VEHICLE_TYPE	2	sedan	0

Scalare (StandardScaler)

Exemplu: primele 5 rânduri pentru CREDIT_SCORE și ANNUAL_MILEAGE

	CREDIT_SCORE	CREDIT_SCORE_scaled	ANNUAL_MILEAGE	ANNUAL_MILEAGE_scaled
0	0.629	0.9247	12000	0.9247
1	0.3578	-1.1602	16000	1.1602
2	0.4931	-0.1197	11000	-0.1197
3	0.206	-2.3265	11000	-2.3265
4	0.3884	-0.925	12000	0.925

e) Interpretarea economică

Din 10,000 clienți am obținut 7,871 înregistrări curate (78.7% reținute).

Imputarea cu media e justificată pentru CREDIT_SCORE și ANNUAL_MILEAGE — distribuții stabile fără variații extreme.

Eliminarea outlierilor previne distorsionarea modelelor predictive — un client cu 50 de accidente ar denatura estimările de risc.